Calibrazione di classificatori probabilistici: Platt scaling e regressione isotonica

Ievgen Potanov

Statistical Methods for Machine Learning — Progetto, Assignment 2

Sommario

In questo progetto studio la calibrazione delle probabilità predette da due classificatori, una regressione logistica implementata da zero e una random forest, su due dataset reali di classificazione binaria (Adult e MAGIC Gamma Telescope). Seguendo l'articolo di Niculescu-Mizil e Caruana [1], misuro la calibrazione con reliability diagram, log-loss, Brier score ed expected calibration error, e la correggo con due metodi di post-processing implementati da zero: Platt scaling e regressione isotonica. La regressione logistica risulta già ben calibrata e la calibrazione non la migliora. La random forest è il modello più accurato ma anche il peggio calibrato: su MAGIC mostra la distorsione a forma di sigmoide descritta nell'articolo, che entrambi i metodi correggono; su Adult la distorsione ha una forma diversa e solo la regressione isotonica la corregge. In tutti i casi la calibrazione lascia praticamente invariata l'accuracy.

1 Introduzione

Nel corso i classificatori vengono addestrati minimizzando una loss surrogata, come la logistic loss, e valutati di solito con l'accuracy. In molte applicazioni però non basta prevedere la classe giusta: serve anche che la probabilità prodotta dal modello sia affidabile, per esempio quando viene usata per stimare un rischio o per scegliere una soglia di decisione diversa da 0.5. Un classificatore con output $p(x) \in [0, 1]$ si dice *calibrato* se

$$\mathbb{P}(Y = 1 \mid p(X) = s) = s \qquad \text{per ogni } s \in [0, 1], \tag{1}$$

cioè se, tra tutti gli esempi a cui assegna probabilità 0.8, circa l'80% è davvero positivo. L'accuracy non misura questa proprietà: dipende solo da quale lato della soglia 0.5 cade la previsione, quindi un modello può avere un'accuracy alta e allo stesso tempo probabilità molto sbagliate.

Niculescu-Mizil e Caruana [1] confrontano le probabilità prodotte da dieci famiglie di algoritmi e osservano che ognuna le distorce in un modo tipico: i metodi a massimo margine (SVM, boosting) tengono le previsioni lontane da 0 e 1 e danno un reliability diagram a forma di sigmoide; naive Bayes le spinge verso 0 e 1; la regressione logistica e le reti neurali sono già ben calibrate; le random forest stanno a metà strada. Mostrano poi che due metodi semplici applicati dopo l'addestramento, *Platt scaling* e *regressione isotonica*, eliminano gran parte della distorsione, purché siano addestrati su dati non usati per il training.

L'obiettivo del progetto è riprodurre questa analisi in piccolo: due modelli (regressione logistica e random forest), due dataset reali, i due metodi di calibrazione, e un confronto prima e dopo la correzione con reliability diagram e metriche quantitative.

2 Dataset e preprocessing

Dataset	Esempi	Feature (originali / dopo codifica)	Classe positiva	% positivi
Adult	48 842	14 / 90	reddito $>$ 50K\$	23.9
MAGIC	19 020	10 / 10	adrone (fondo)	35.2

Tabella 1: I due dataset usati.

Ho usato due dataset reali di classificazione binaria del repository UCI (Tabella 1).

Adult contiene dati di un censimento americano; il compito è prevedere se una persona guadagna più di 50 mila dollari all'anno. L'ho scelto perché è uno degli otto dataset dell'articolo, quindi posso confrontare direttamente il comportamento dei modelli con quello descritto dagli autori. Ha attributi sia numerici sia categorici. Nel preprocessing ho eliminato `fnlwgt` (un peso di campionamento del censimento, non una caratteristica della persona) ed `education` (ridondante con `education-num`), ho applicato $\log(1+x)$ a `capital-gain` e `capital-loss`, che sono quasi sempre zero con pochi valori enormi, ho codificato gli attributi categorici con one-hot encoding (i valori mancanti diventano una categoria a sé) e ho standardizzato quelli numerici.

MAGIC Gamma Telescope contiene dieci misure continue di sciami di particelle simulati in un telescopio Cherenkov; il compito è distinguere i segnali gamma dal fondo adronico. L'ho scelto perché è molto diverso da Adult: tutte le feature sono continue e non ci sono attributi categorici. A posteriori, il divario di accuracy tra regressione logistica (79%) e random forest (88%) indica che il confine tra le classi non è lineare e che un modello lineare non riesce a catturarlo del tutto. Qui il preprocessing è solo la standardizzazione.

Entrambi i dataset sono di dimensione media: abbastanza grandi da avere un calibration set di qualche migliaio di esempi (importante per la regressione isotonica), ma abbastanza piccoli da far girare tutti gli esperimenti in circa un minuto. I file sono scaricati dalla raccolta PMLB, che ridistribuisce i dataset UCI originali in formato tabellare; il codice li scarica automaticamente alla prima esecuzione.

3 Metodi

Tutte le componenti per cui la consegna non consente l'uso di librerie sono implementate da zero con `numpy`: regressione logistica, Platt scaling, regressione isotonica, metriche e reliability diagram. La random forest è quella di `scikit-learn`, come permesso dal testo del progetto.

3.1 Regressione logistica

Il modello predice $p(x) = \sigma(w^\top x + b)$ con $\sigma(z) = 1/(1+e^{-z})$. I parametri si ottengono minimizzando sul training set la log-loss media con una penalità L_2 sui pesi:

$$\min_{w,b} \; \frac{1}{n}\sum_{i=1}^{n} \Big[-y_i \log p_i - (1-y_i)\log(1-p_i) \Big] + \frac{\lambda}{2}\|w\|^2. \tag{2}$$

La funzione è convessa, quindi ho usato la discesa del gradiente full-batch, con gradienti $\nabla_w = \frac{1}{n}\sum_i (p_i - y_i)x_i + \lambda w$ e $\nabla_b = \frac{1}{n}\sum_i (p_i - y_i)$, learning rate $\eta = 1$, $\lambda = 10^{-3}$ (il bias non è regolarizzato), al massimo 5000 iterazioni e arresto anticipato quando la norma del gradiente scende sotto 10^{-6}. Le feature sono standardizzate, quindi un passo fisso funziona bene. Un'osservazione utile per dopo: la regressione logistica è addestrata proprio minimizzando la log-loss, cioè a produrre probabilità il più possibile vicine a quelle vere, quindi ci si aspetta che sia già calibrata quando il modello lineare è adeguato ai dati.

3.2 Random forest

Ho usato `RandomForestClassifier` con 300 alberi e le altre impostazioni di default (alberi completamente sviluppati, $\sqrt{d}$ feature candidate per ogni split). La probabilità predetta è la media, sui 300 alberi, delle frequenze di classe nelle foglie raggiunte. Non ho ottimizzato gli iperparametri, perché lo scopo è studiare la calibrazione di un modello tipico, non massimizzare l'accuracy.

3.3 Platt scaling

Platt scaling trasforma il punteggio f di un classificatore già addestrato in

$$P(y = 1 \mid f) = \frac{1}{1 + \exp(Af + B)}, \tag{3}$$

dove A e B sono stimati sul calibration set minimizzando la log-loss. È quindi una regressione logistica con una sola feature, il punteggio f, e nell'implementazione riuso semplicemente la classe della regressione logistica (senza regolarizzazione). Prima dell'addestramento standardizzo f, così lo stesso learning rate funziona sia con i logit della regressione logistica sia con le probabilità della random forest, e poi riporto A e B alla scala originale. Come nell'articolo, al posto delle etichette 0/1 uso i target

$$y_+ = \frac{N_+ + 1}{N_+ + 2}, \qquad y_- = \frac{1}{N_- + 2}, \tag{4}$$

dove N_+ e N_- sono il numero di positivi e negativi del calibration set. Il motivo è che la sigmoide non raggiunge mai 0 o 1: avere $\sigma(z) = 1$ richiederebbe $z = \ln \frac{p}{1-p} = +\infty$. Con target 1, l'errore $\sigma(z_i) - 1$ resta sempre negativo, il gradiente non si annulla mai e, se i punteggi separano le classi, la discesa del gradiente fa crescere $|A|$ senza limite: la sigmoide diventa sempre più ripida, fino a un gradino che restituisce solo 0 o 1. Con i target (4) il valore da raggiungere è finito, $\ln \frac{y_+}{1-y_+} = \ln(N_+ + 1)$: il gradiente può annullarsi. Per la regressione logistica il punteggio f è il logit $w^\top x + b$ (così $A = -1$, $B = 0$ riproduce il modello originale); per la random forest è la probabilità predetta, l'unico punteggio disponibile.

3.4 Regressione isotonica

La regressione isotonica non impone nessuna forma alla correzione: assume solo che la probabilità calibrata sia una funzione non decrescente m del punteggio, e cerca quella più vicina alle etichette in errore quadratico:

$$\hat{m} = \arg \min_{m \text{ non decrescente}} \sum_{i=1}^{n} \big(y_i - m(f_i)\big)^2. \tag{5}$$

La soluzione è una funzione a gradini e si calcola con l'algoritmo Pool Adjacent Violators (PAV): si ordinano gli esempi per punteggio, ogni esempio parte come blocco a sé con valore uguale alla sua etichetta, e si fondono ripetutamente i blocchi adiacenti che violano l'ordine, sostituendoli con un blocco il cui valore è la loro media pesata. Alla fine ogni gradino vale la frazione di positivi tra gli esempi che contiene. Nella mia implementazione i blocchi sono gestiti con una pila, così dopo ogni fusione basta controllare il blocco precedente, e gli esempi con lo stesso punteggio partono nello stesso blocco, così ricevono lo stesso valore. Un nuovo punteggio riceve il valore del gradino in cui cade (ricerca binaria sugli estremi dei blocchi). A differenza di Platt scaling, la regressione isotonica può restituire esattamente 0 o 1, se il primo o l'ultimo gradino contiene una sola classe.

Entrambi i metodi sono funzioni crescenti del punteggio: non cambiano l'ordine degli esempi ma solo i valori, quindi ci si aspetta che l'accuracy cambi poco e la calibrazione molto.

3.5 Metriche e reliability diagram

Sul test set calcolo:

- **accuracy**, con soglia 0.5;
- **log-loss** $-\frac{1}{n}\sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)]$, con p_i limitato a $[10^{-15}, 1-10^{-15}]$ come in `scikit-learn` per evitare $\log 0$;
- **Brier score** $\frac{1}{n}\sum_i (p_i - y_i)^2$, cioè l'errore quadratico medio tra probabilità ed etichetta;
- **expected calibration error** (ECE) $= \sum_{b=1}^{B} \frac{n_b}{n} |\bar{p}_b - \bar{y}_b|$, dove $[0,1]$ è diviso in $B = 10$ bin di uguale ampiezza, n_b è il numero di esempi nel bin b, $\bar{p}_b$ la loro probabilità media e $\bar{y}_b$ la loro frazione di positivi.

Log-loss e Brier score misurano la qualità complessiva delle probabilità; la log-loss è molto più severa, perché un singolo errore commesso con probabilità vicina a 0 o 1 costa tantissimo. L'ECE non è richiesta dalla consegna, ma l'ho aggiunta perché misura solo la calibrazione e riassume il reliability diagram in un numero (la distanza media dalla diagonale, pesata per il numero di esempi).

Il reliability diagram segue l'articolo: 10 bin di uguale ampiezza e, per ogni bin non vuoto, la probabilità predetta media (asse x) contro la frazione di positivi osservata (asse y). Un modello calibrato sta sulla diagonale; punti sotto la diagonale indicano che il modello sovrastima la probabilità del positivo, punti sopra che la sottostima.

4 Protocollo sperimentale

Ogni dataset è diviso in modo stratificato in training set (60%), calibration set (20%) e test set (20%): 29 304/9 769/9 769 esempi per Adult e 11 412/3 804/3 804 per MAGIC. I modelli sono addestrati solo sul training set, Platt scaling e regressione isotonica sui punteggi del calibration set, e tutte le metriche sono calcolate sul test set. Il calibration set separato è necessario perché il calibratore è a sua volta un modello che impara dai dati: sul training set i punteggi del modello sono ottimisticamente distorti (la random forest, per esempio, lì ha un'accuracy vicina al 100%), quindi il calibratore imparerebbe a fidarsi troppo del modello; usare il test set renderebbe invece la valutazione ottimistica. Per evitare ogni data leakage, anche le statistiche del preprocessing (medie, deviazioni standard, categorie del one-hot) sono stimate solo sul training set e poi applicate agli altri due insiemi. L'intera procedura è ripetuta su 5 split casuali (seed 0–4) e riporto media e deviazione standard; i grafici si riferiscono al primo split.

Per verificare le implementazioni, lo script `sanity_checks.py` le confronta con quelle di `scikit-learn` sugli stessi dati (queste ultime non sono mai usate negli esperimenti): le probabilità della mia regressione logistica differiscono da `LogisticRegression` con regolarizzazione equivalente al massimo di $6 \cdot 10^{-3}$, la regressione isotonica coincide con `IsotonicRegression` a meno di errori di arrotondamento e le metriche coincidono esattamente.

5 Risultati

5.1 Confronto quantitativo

La Tabella 2 riporta le metriche sul test set. Come previsto, l'accuracy è praticamente invariata dalla calibrazione: le variazioni sono entro una deviazione standard, perché entrambi i metodi sono monotoni e cambiano la classe solo di pochi esempi vicini alla soglia.

Regressione logistica. Su Adult la regressione logistica è già ben calibrata (ECE 0.012) e nessuno dei due metodi la migliora. Nel primo split Platt scaling impara $A \approx -1.02$ e $B \approx -0.03$, cioè quasi l'identità sul logit: in pratica il calibratore non ha nulla da correggere. La regressione isotonica peggiora leggermente la log-loss. Su MAGIC l'ECE è un po' più alta (0.026) e la regressione isotonica la riduce a 0.018, ma il Brier score resta uguale e la log-loss peggiora: qui il problema non

Modello	Metodo	Accuracy	Log-loss	Brier	ECE
Adult					
LR	Non calibrato	0.8476 ± 0.002	0.3288 ± 0.005	0.1053 ± 0.001	0.0116 ± 0.004
LR	Platt	0.8480 ± 0.002	0.3286 ± 0.005	0.1054 ± 0.001	0.0107 ± 0.003
LR	Isotonica	0.8464 ± 0.003	0.3327 ± 0.005	0.1056 ± 0.001	0.0112 ± 0.002
RF	Non calibrato	0.8508 ± 0.001	0.4016 ± 0.018	0.1064 ± 0.002	0.0365 ± 0.005
RF	Platt	0.8526 ± 0.002	0.3478 ± 0.005	0.1070 ± 0.002	0.0360 ± 0.001
RF	Isotonica	0.8522 ± 0.001	0.3330 ± 0.005	0.1047 ± 0.001	0.0135 ± 0.003
MAGIC					
LR	Non calibrato	0.7901 ± 0.004	0.4544 ± 0.006	0.1460 ± 0.003	0.0260 ± 0.004
LR	Platt	0.7903 ± 0.003	0.4543 ± 0.007	0.1460 ± 0.003	0.0225 ± 0.004
LR	Isotonica	0.7923 ± 0.005	0.4677 ± 0.016	0.1458 ± 0.003	0.0178 ± 0.002
RF	Non calibrato	0.8837 ± 0.008	0.2978 ± 0.010	0.0891 ± 0.004	0.0361 ± 0.007
RF	Platt	0.8839 ± 0.009	0.2933 ± 0.014	0.0876 ± 0.005	0.0171 ± 0.005
RF	Isotonica	0.8830 ± 0.008	0.3073 ± 0.023	0.0877 ± 0.005	0.0132 ± 0.003

Tabella 2: Metriche sul test set (media ± deviazione standard su 5 split casuali).

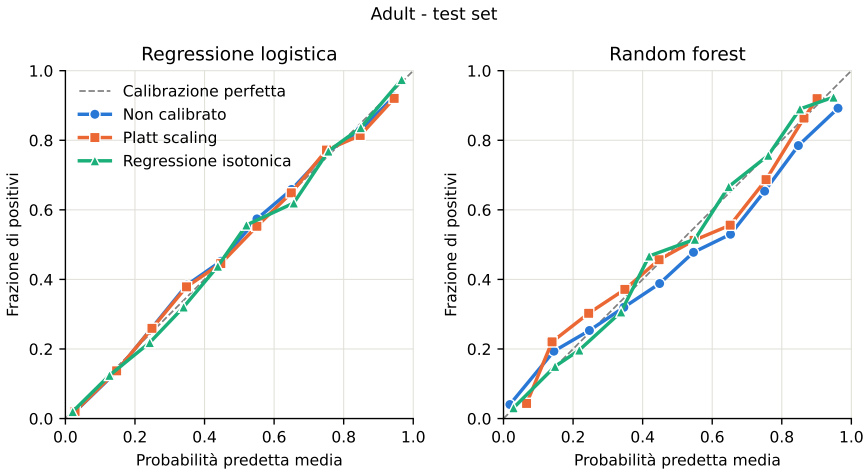


Figura 1: Adult: reliability diagram prima e dopo la calibrazione sul test set del primo split.

è la calibrazione, ma il fatto che un modello lineare non riesce a rappresentare il confine tra le classi, e una trasformazione del punteggio non può aggiungere informazione che il punteggio non contiene.

Random forest. La random forest è il modello più accurato su entrambi i dataset, ma prima della calibrazione ha un'ECE circa tre volte quella della regressione logistica (0.037 su Adult, 0.036 su MAGIC). Su MAGIC entrambi i metodi funzionano: l'ECE scende a 0.017 con Platt scaling e a 0.013 con la regressione isotonica, e migliora anche il Brier score. Su Adult invece Platt scaling non migliora l'ECE (0.036), mentre la regressione isotonica la porta a 0.014 e ottiene il miglior Brier score di tutta la tabella su Adult. La log-loss della random forest non calibrata su Adult è molto alta (0.40) perché circa il 23% delle sue previsioni sul test set è esattamente 0 o 1 (tutti i 300 alberi d'accordo) e nel primo split 20 di queste sono sbagliate: ognuna costa $-\log 10^{-15} \approx 34.5$. Entrambi i calibratori eliminano questi valori estremi, e la log-loss scende a 0.35 e 0.33.

5.2 Reliability diagram

Le Figure 1 e 2 mostrano le curve di calibrazione prima e dopo la correzione.

Per la regressione logistica su Adult le tre curve stanno sulla diagonale. Su MAGIC la curva non calibrata è leggermente sopra la diagonale tra 0.3 e 0.6 (il modello sottostima un po' la probabilità del positivo nella zona incerta) e le curve calibrate restano vicine a quella originale.

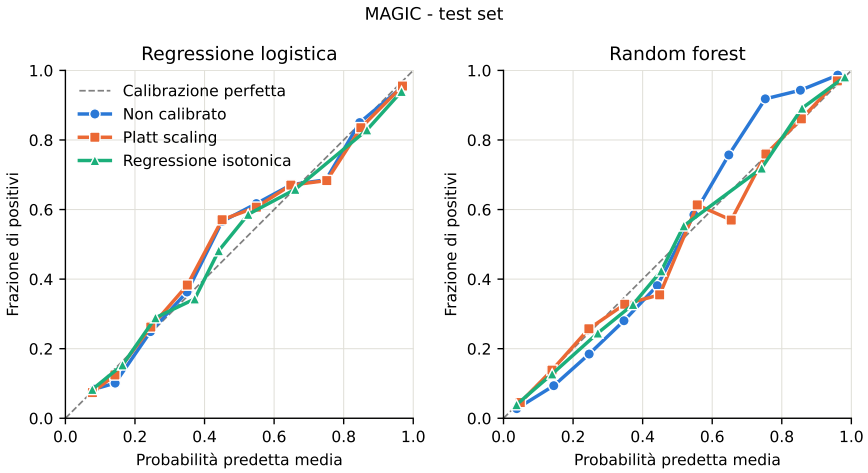


Figura 2: MAGIC: reliability diagram prima e dopo la calibrazione sul test set del primo split.

La random forest su MAGIC mostra la distorsione a forma di S descritta nell'articolo: a sinistra i punti stanno sotto la diagonale (quando dice 0.15 succede circa il 10% delle volte) e a destra sopra (quando dice 0.75 succede circa il 92% delle volte). Le probabilità sono schiacciate verso il centro, il modello è troppo prudente. Dopo la calibrazione entrambe le curve seguono la diagonale.

La random forest su Adult si comporta diversamente. Sopra 0.4 la curva sta sotto la diagonale: il modello sovrastima la probabilità di reddito alto, mentre a sinistra è quasi corretto. Non è una S simmetrica, e infatti Platt scaling sposta l'errore invece di eliminarlo: dopo la correzione la curva è sopra la diagonale tra 0.2 e 0.4 e ancora sotto intorno a 0.6–0.7, perché una sigmoide con due parametri non può abbassare la zona alta senza toccare anche quella bassa. La regressione isotonica, che può seguire qualsiasi forma crescente, riporta la curva sulla diagonale.

6 Discussione

Perché i modelli sono (mis)calibrati. La regressione logistica minimizza la log-loss, cioè è addestrata direttamente a produrre probabilità corrette: quando il modello lineare è adeguato (Adult) le sue probabilità sono calibrate senza bisogno di post-processing, come afferma l'articolo. Quando non lo è (MAGIC) la miscalibrazione che si vede dipende dal punteggio stesso, che è poco informativo, e un post-processing monotono può ridurla solo in parte. La random forest invece non ottimizza nessuna loss sulle probabilità: la sua probabilità è una media di voti di alberi molto variabili. Come spiega l'articolo, questa media è distorta vicino agli estremi: per predire 0 tutti gli alberi devono predire 0, quindi basta il rumore di pochi alberi per spostare verso il centro una previsione che dovrebbe essere estrema. È la forma a S che si vede su MAGIC. Su Adult il quadro è più misto: molti esempi finiscono in zone in cui tutti gli alberi sono d'accordo (esattamente 0), e la zona ad alta probabilità è sovrastimata. Il comportamento della random forest dipende quindi dal dataset, in linea con l'osservazione dell'articolo che per le random forest il risultato è "less clear cut".

Platt scaling e regressione isotonica a confronto. Platt scaling funziona bene quando la distorsione ha davvero forma di sigmoide (random forest su MAGIC); ha solo due parametri, quindi è stabile, e il suo output non raggiunge mai 0 o 1. Il suo limite si vede su Adult, dove la distorsione ha un'altra forma e la sigmoide non riesce a seguirla. La regressione isotonica corregge qualsiasi distorsione monotona e ottiene l'ECE più bassa in tre casi su quattro, ma ha molti più gradi di libertà, quindi ha bisogno di più dati di calibrazione (l'articolo mostra che con poche centinaia di esempi va in overfitting e Platt scaling è preferibile), e la sua funzione a gradini può restituire esattamente 0 o 1. Questo spiega la sua log-loss peggiore su tre coppie modello/dataset: nel primo

split solo 2–3 esempi di test ricevono una probabilità sbagliata esattamente uguale a 0 o 1, ma ognuno costa circa $34.5/n$. Le metriche quindi non sono sempre d'accordo: Brier score ed ECE premiano la regressione isotonica, la log-loss punisce pesantemente quei pochi errori "sicuri". Una correzione semplice sarebbe limitare l'output della regressione isotonica a $[\varepsilon, 1-\varepsilon]$; ho preferito riportare l'algoritmo base, come nell'articolo.

Confronto con l'articolo. I risultati concordano con l'articolo sui punti principali: la regressione logistica è ben calibrata e non trae beneficio dalla calibrazione; la random forest può mostrare una distorsione sigmoidale, corretta da entrambi i metodi; la calibrazione non cambia l'accuracy. La differenza principale è la random forest su Adult, la cui distorsione non è sigmoidale. Una spiegazione plausibile è il diverso setting: l'articolo addestra su 4000 esempi e seleziona la migliore tra molte configurazioni, mentre io uso alberi completamente sviluppati con impostazioni di default su circa 29 000 esempi, e questo produce molte previsioni unanimi esattamente a 0.

Limiti. Gli iperparametri non sono stati ottimizzati: una random forest con foglie più grandi sarebbe forse meglio calibrata in partenza. L'ECE dipende dal numero di bin ed è rumorosa dove i bin hanno pochi esempi. I risultati sono mediati su soli 5 split di due dataset e alcune differenze nella Tabella 2 sono entro una deviazione standard; in particolare non si può dire che Platt scaling e regressione isotonica siano diversi per la random forest su MAGIC. Infine, entrambi i metodi sono pensati per problemi binari.

7 Conclusioni

Ho implementato da zero regressione logistica, Platt scaling, regressione isotonica e le metriche di valutazione, e le ho usate per studiare la calibrazione su Adult e MAGIC. Il risultato principale è che una buona accuracy non implica buone probabilità: la random forest è il modello più accurato su entrambi i dataset ma anche il peggio calibrato. La calibrazione a posteriori su un calibration set separato corregge gran parte del problema senza toccare l'accuracy: Platt scaling quando la distorsione è sigmoidale o i dati sono pochi, regressione isotonica quando i dati di calibrazione sono sufficienti e la distorsione ha un'altra forma. Un modello che minimizza già la log-loss ed è adeguato al problema, come la regressione logistica su Adult, va lasciato com'è.

Riproducibilità

Il codice è nel repository insieme a questo report. Dopo aver installato le dipendenze (`pip install -r requirements.txt`), `python main.py` scarica i dataset, esegue tutti gli esperimenti con seed fissati e scrive in `results/` i file CSV con le metriche e le figure usate nel report; `python sanity_checks.py` esegue il confronto con `scikit-learn`. L'esecuzione completa richiede circa un minuto su un portatile.

Declaration

I declare that this material, which I now submit for assessment, is entirely my own work and has not been taken from the work of others, save and to the extent that such work has been cited and acknowledged within the text of my work. I understand that plagiarism, collusion, and copying are grave and serious offences in the university and accept the penalties that would be imposed should I engage in plagiarism, collusion or copying. This assignment, or any part of it, has not been previously submitted by me or any other person for assessment on this or any other course of study.

Riferimenti bibliografici

[1] A. Niculescu-Mizil and R. Caruana. Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 2005.